


Text Mining para Ciência de Dados

(03492)

2025/2026 - 2º Semestre



Apresentação



Docentes

Fernando Batista



fernando.batista@iscte-iul.pt

Ricardo Ribeiro



ricardo.ribeiro@iscte-iul.pt

Gabinete D6.21

Objetivos

- Conhecer o **potencial das grandes quantidades de texto** atualmente disponíveis e os **métodos computacionais** que podem ser utilizados para **extrair conhecimento** a partir desses dados.
 - Conhecer os conceitos básicos e abordagens práticas
 - Ênfase nas abordagens gerais de Língua Natural
- Conhecer as **aplicações realizáveis** com as tecnologias atuais
- Proporcionar uma **experiência prática na utilização de toolkits** e na implementação de algoritmos, através da sua aplicação específica a tarefas tais como análise de sentimento e modelação de tópicos

Metodologia

- Aulas
 - 8 semanas de aulas teórico-práticas (3h)
- Recursos necessários
 - Ambiente de desenvolvimento de software (Python)
 - Acesso à Internet e um browser (e.g. firefox)
- Informação
 - <https://fenix-mais.iscte-iul.pt/>
 - <https://moodle.iscte-iul.pt/>
 - <https://github.com/HLT-ISCTE/Text-Mining>

Avaliação

- Esta UC é feita apenas por avaliação ao longo do semestre, não contemplando a modalidade de avaliação por exame
- A avaliação consiste em duas componentes
 - TESTES (50%)
 - 2 mini-testes (5% cada) + 1 teste final (40%), realizados durante o período letivo;
 - TRABALHO (50%)
 - trabalho de avaliação, realizado em grupos de 2 a 3 estudantes
- Notas
 - Em caso de reprovação, a nota de TESTES pode ser substituída por uma prova escrita a realizar no período de avaliação correspondente à 1º época, 2ª época ou época especial (Artº 14 do RGACC)
 - A nota de TRABALHO está limitada à nota de **TESTES + 6 valores**.
 - A assiduidade não é requisito essencial de aprovação

Planeamento

#	Semana	18h00	19h30
1	25-Feb	Apresentação, Introdução: obtenção e filtragem de informação, aplicações	Introdução ao Python, Jupyter, Orange3
2	4-Mar	preparação de dados: tokenization, normalization, Doc. representation	Exercícios: TD-IDF, similaridade entre documentos Mini-teste 1 - Online
3	11-Mar	NLP: lematização, morfologia, sintaxe, semântica, NER, relations extraction	Exercícios: Bibliotecas de NLP, NLTK, Spacy, etc.
4	18-Mar	Classificação de Texto	Classificação de Texto Mini-teste 2 - Online
5	25-Mar	Análise de Sentimento + Enunciado Projeto	Topic Modelling Enunciado do projeto
	1-Apr	Páscoa	
	8-Apr	Semana de avaliações: Teste final (40%) Teste final	
6	15-Apr	Transformadores e LLMs: encoders, decoders, fine-tuning, prompting	Apoio ao projeto
7	22-Apr	Apoio ao projeto	Apoio ao projeto
8	29-Apr	Apresentações	Apresentações Entrega do projeto

Mini-testes: ~10 perguntas, 30 minutos, Quinta a Sábado, a melhor de 2 tentativas

Recursos

- Python / Jupyter Notebooks
 - <https://github.com/HLT-ISCTE/Text-Mining>
- Google Colaboratory
 - <https://colab.research.google.com/>
- Orange3 data mining


Text Mining

Fernando Batista, Ricardo Ribeiro e Eugénio Ribeiro

 Open in Colab

Conteúdo

1. Introdução ao Python e ao Jupyter Notebook (opcional)
 - [Jupyter notebook e exemplos introdutórios de Python](#)
 - Homework: [Introduction to Python](#) and [exercises](#)
 - [Leitura de ficheiros CSV](#)
 - [Download dos dados utilizados nos exemplos](#)
2. Pré-processamento com vista à representação de documentos
 - [Tokenização](#) - tokenização básica, tokenização com NLTK, tokenização de tweets
 - [NLP libraries](#) for tokenization, sentence segmentation, stemming, part-of-speech, NER and sentiment analysis




E depois de Text Mining?

- Google
- Microsoft
- Lucent
- Unbabel
- Visor.ai
- Bloomberg
- ...
- nlp people


E depois de Text Mining?

- Google
- Microsoft
- Lucent
- Unbabel
- Visor.ai
- Bloomberg
- ...
- nlp people



E depois de Text Mining?

- Google
- Microsoft
- Lucent
- Unbabel
- Visor.ai
- Bloomberg
- ...
- [nlp people](#)




E depois de Text Mining?

- Google
- Microsoft
- Lucent
- Unbabel
- Visor.ai
- Bloomberg
- ...
- nlp people



E depois de Text Mining?

- Google
- Microsoft
- Lucent
- Unbabel
- Visor.ai
- Bloomberg
- ...
- nlp people



Bibliografia

- Principal

- Charu C. Aggarwal (2018). Machine Learning for Text. <https://doi.org/10.1007/978-3-319-73531-3>
- Gabe Ignatow, Rada F. Mihalcea (2017). An Introduction to Text Mining: Research Design, Data Collection, and Analysis 1st Edition (2017). SAGE Publications
- Dan Jurafsky and James H. Martin (2023). Speech and Language Processing (3rd ed. draft). <https://web.stanford.edu/~jurafsky/slp3/>

- Complementar

- Atefeh Farzindar and Diana Inkpen (2017). Natural Language Processing for Social Media, Second Edition. Synthesis Lectures on Human Language Technologies. Morgan & Claypool.
- Jacob Eisenstein (2019). Introduction to Natural Language Processing. The MIT Press.

Análise do background dos estudantes

- Por favor, preencher o seguinte questionário (em casa)
 - <https://t.ly/yn2Dz>